

1. Bedrock 모델 액세스 설정

(중요) 모든 작업은 us-east-1 (버지니아 북부)에서 진행합니다.

The screenshot shows the Amazon Bedrock console interface. On the left sidebar, under 'Bedrock configurations', the '모델 액세스' (Model Access) link is highlighted with a red box and a red '1'. The main content area shows the '모델 액세스' page. At the top, there's a section titled '모델 액세스란 무엇입니까?' (What is Model Access?) with a red '2' and a red box around the '모델 액세스 권한 수정' (Modify Model Access Permissions) button. Below this, there's a section titled '기반 모델 (47)' (Base Models (47)) listing various models like Jamba 1.5 Mini, Jamba 1.5 Large, Jamba-Instruct, Jurassic-2 Ultra, Jurassic-2 Mid, Titan Embeddings G1 - Text, Titan Text G1 - Lite, Titan Text G1 - Express, Titan Image Generator G1 v2, Titan Image Generator G1, Nova Reel, and Titan Multimodal Embeddings G1.

☐ Anthropic (9)

☒ Claude 3.5 Haiku [Cross-region inference](#)

☒ Claude 3.5 Sonnet v2 [Cross-region inference](#)

☒ Claude 3.5 Sonnet

☐ Claude 3 Opus [Cross-region inference](#)

☒ Claude 3 Sonnet

☐ Titan Multimodal Embeddings G1

☐ Titan Text Embeddings V2

취소

다음

두 모델 중 택 1

아래 두 모델의 액세스 권한을 확인

Claude 3.5 Haiku

액세스 권한 부여됨

에이전트, 채팅 최적화됨, 코드 생성, 복잡한 추론 및 분석, 대화, 수학, Multilingual...

Serverless

Titan Text Embeddin...

액세스 권한 부여됨

출력 벡터 크기 = 1,024(기본값), 512 또는 256

Serverless

2. Bedrock 지식 기반 생성

Faq.zip 파일의 압축을 풀고, 해당 디렉토리내 모든 파일을 s3 버킷에 업로드

업로드 정보

S3에 업로드할 파일 및 폴더를 추가합니다. 160GB보다 큰 파일을 업로드하려면 AWS CLI, AWS SDK 또는 Amazon S3 REST API를 사용합니다. [자세히 알아보기](#)

여기에 업로드할 파일과 폴더를 붙여넣거나, 파일 추가 또는 폴더 추가를 선택합니다.

파일 및 폴더 (157 항목, 61.9KB)

이 테이블의 모든 파일과 폴더가 업로드됩니다.

이름으로 찾기

☒	이름	폴더	유형	크기
☒	회원_12.txt	faq/	text/plain	399.0B
☒	회원_14.txt	faq/	text/plain	373.0B
☒	회원_17.txt	faq/	text/plain	267.0B
☒	회원_18.txt	faq/	text/plain	259.0B
☒	회원_19.txt	faq/	text/plain	202.0B
☒	회원_20.txt	faq/	text/plain	372.0B
☒	회원_21.txt	faq/	text/plain	239.0B
☒	특징_08.txt	faq/	text/plain	351.0B
☒	특징_09.txt	faq/	text/plain	324.0B
☒	특징_10.txt	faq/	text/plain	391.0B

대상 정보

대상

s3://straight-chatbot3

다음과 같은 설정을 준수하여, Bedrock 지식 기반 생성

1

테스트

Evaluate

지식 기반 생성 ▲

Knowledge Base with vector store

지식 기반 세부 정보 제공

지식 기반 세부 정보

지식 기반 이름

knowledge-base-quick-start-ljxe2

유효한 문자는 a-z, A-Z, 0-9, _ (언더바) 및 - (하이픈)입니다. 이름은 최대 50자까지 입력할 수 있습니다.

지식 기반 설명 - 선택 사항

설명 입력

유효한 문자는 a-z, A-Z, 0-9, _ (언더바) 및 - (하이픈)입니다. 이름은 최대 200자까지 입력할 수 있습니다.

IAM 권한

IAM 역할은 사용자를 대신하여 다른 서비스에 액세스하는 데 사용됩니다. [service role](#) for Amazon Bedrock

권한 역할

- ☒ 새 서비스 역할 생성 및 사용
☐ 기존 서비스 역할 사용

서비스 역할 이름

AmazonBedrockExecutionRoleForKnowledgeBase_ljxe2

Data source details

Choose data source

Select the data source that you want to configure in the next step. You can add up to 5 data sources in a Knowledge Base.

Amazon S3
Object storage service that stores data as objects within buckets.

Web Crawler - Preview
Web page crawler that extracts content from public web pages you are authorized to crawl.

Custom
Create a data source directly in Amazon Bedrock. A custom data source allows the flexibility to automatically ingest documents into your vector database directly.

Confluence - Preview
Collaborative work management tool designed for project planning, software development and product management.

Salesforce - Preview
Customer relationship management (CRM) tool for managing support, sales, and marketing data.

Sharepoint - Preview
Collaborative web-based service for working on documents, web pages, web sites, lists, and more.

2. 중요!!

데이터 소스 구성

선택한 데이터 소스에 맞게 구성

Amazon S3

Amazon Bedrock을 S3 데이터 소스에 연결하기 위한 세부 정보를 제공하세요.

▼ 데이터 소스: knowledge-base-quick-start-c95mi-data-source

삭제

데이터 소스 이름

knowledge-base-quick-start-c95mi-data-source

유효한 문자는 a-z, A-Z, 0-9, _ (밑줄) 및 - (하이픈)입니다. 이름은 최대 100자까지 입력할 수 있습니다.

데이터 소스 위치

☒ 이 AWS 계정

☐ 다른 AWS 계정

이전에 파일을 업로드 한 S3 선택

S3 URI

S3 URI

s3://straight-chatbotv3

X

보기

S3 찾아보기

☐ S3 데이터를 고객 관리형 KMS 키 추가 - 선택 사항

S3 데이터를 암호화한 경우 Bedrock이 암호를 복호화할 수 있도록 여기에 KMS 키를 제공합니다.

Parsing strategy

Select a parsing option to configure how your data is processed. You can't modify this option after the knowledge base is created.

☒ Amazon Bedrock default parser

Select this option to only process text from your data. This parser doesn't incur charges.

☐ Foundation models as a parser

Select this option to process visually rich documents or images. With this option, you can use the default parser prompt or customize it for your use case. [Pricing details](#)

정형 전략

정형은 임베딩하기 전에 텍스트를 더 작은 세그먼트로 나눕니다. 정형 전략은 데이터 소스를 만든 후에는 수정할 수 없습니다.

정형 없음

이 옵션은 문서를 별도의 파일로 분할하여 사전 처리한 경우, Bedrock이 문서를 더 이상 청크로 만들지 않도록 하려는 경우에 적합합니다.

▶ Transformation function - 선택 사항

▶ 고급 설정 - 선택 사항

데이터 소스 추가

최대 5개의 데이터 소스.

3

임베딩 모델 선택 및 벡터 저장소 구성

다음 단계에서 제공할 데이터를 변환할 임베딩 모델을 선택하고, Bedrock이 임베딩을 저장, 관리 및 업데이트할 수 있는 벡터 데이터 저장소에 대한 세부 정보를 제공합니다. 지식 기반 생성 후에는 임베딩 모델 및 벡터 저장소를 변경할 수 없습니다.

임베딩 모델

데이터를 임베딩으로 변환하려면 임베딩 모델을 선택합니다. 가격은 모델에 따라 다릅니다. 자세히 알아보기

Titan Text Emb...
온디맨드

상기 Access 허가 한 모델 선택

▶ Additional configurations

벡터 데이터베이스

Amazon이 회원님을 대신하여 벡터 저장소를 생성하거나 이전에 생성된 저장소를 선택하여 Bedrock이 임베딩을 저장, 업데이트 및 관리할 수 있도록 하세요. 벡터 저장소 제공업체로부터 직접 요금이 청구됩니다. 자세히 알아보기

Vector store creation method

☒ 새로운 벡터 저장소 백본 생성 - 권장

Choose one of the vector stores below to create a new vector store.

☐ 생성한 벡터 저장소를 선택하세요

Select Amazon OpenSearch Serverless, Amazon Aurora, Pinecone, Amazon Aurora, MongoDB Atlas, Neptune Analytics (GraphRAG) or Redis Enterprise Cloud and provide field mappings.

Vector store

If you've used a vector store before, we recommend that you continue using it. Otherwise, choose the vector store that best fits your use case.

☒ Amazon OpenSearch Serverless

Select to optimize and provide contextually relevant responses across billions of vectors in milliseconds. Combine search with text-based keywords for hybrid requests. [Learn more](#)

☐ Amazon Aurora PostgreSQL Serverless - new

Select to store and index vector embeddings for fast similarity search. Use SQL queries to combine search results with your business data. [Learn more](#)

☐ Amazon Neptune Analytics (GraphRAG) - Preview

Select to optimize for high-performance graph analytics and enable graph-based Retrieval Augmented Generation (GraphRAG) solutions. 자세히 알아보기

▶ Additional configurations

4

Amazon Bedrock > 지식 기반 > knowledge-base-quick-start-23e9t

knowledge-base-quick-start-23e9t

지식 기반 개요

지식 기반 이름
knowledge-base-quick-start-23e9t

지식 기반 설명
—

서비스 역할
AmazonBedrockExecutionRoleForKnowledgeBase_23e9t [링크](#)

지식 기반 ID
 WGK3RORLNX

상태
 사용 가능

생성 날짜
February 14, 2025, 09:09 (UT

지식 기반 생성 후, 반드시 데이터 소스와 동기화 진행

데이터 소스 (1)

데이터 소스에는 지식 기반을 쿼리할 때 반환되는 정보가 포함됩니다.

 동기화

🔍 데이터 소스 찾기

☒	데이터 소스 이름	▼	상태	데이터 소스
☒	knowledge-base-quick-s...		 Available	S3

3.Bedrock 가드레일 설정

1

Amazon Bedrock > 가드레일 > 가드레일 생성

- 1단계 가드레일 세부 정보 제공
- 2단계 - 선택 사항 콘텐츠 필터 구성
- 3단계 - 선택 사항 거부된 주제 추가
- 4단계 - 선택 사항 단어 필터 추가
- 5단계 - 선택 사항 민감한 정보 필터 추가
- 6단계 - 선택 사항 컨텍스트 근거 검사 추가
- 7단계 검토 및 생성

가드레일 세부 정보 제공

가드레일 세부 정보

이름

Autobot_Guardrail

유효한 문자는 a~z, A~Z, 0~9, _ (밑줄) 및 -(하이픈)입니다. 이름은 최대 50자까지 입력할 수 있습니다.

설명 - optional

오토봇의 가드레일

설명은 최대 200자까지 입력할 수 있습니다.

차단된 프롬프트에 대한 메시지

가드레일이 사용자 프롬프트를 차단하는 경우 표시할 메시지를 입력합니다.

죄송합니다. 해당 모델은 현대/기아 차량과 관련된 질문에만 답할 수 있습니다.

메시지는 최대 500자까지 입력할 수 있습니다.

☒ 동일한 차단 메시지를 응답에 적용

▶ KMS key selection - optional

2

콘텐츠 필터 구성 - 선택 사항

필터링 수준을 조정하여 사용 정책을 위반하는 유해한 사용자 입력 및 모델 응답을 탐지하고 차단하는 콘텐츠 필터를 구성할 수 있습니다. [Learn more](#)

유해 카테고리

유해한 사용자 입력 및 모델 응답을 감지하고 차단할 수 있습니다. 필터 강도를 높이면 특정 카테고리에서 유해한 콘텐츠를 필터링할 가능성이 높아집니다.

☒ 유해 카테고리 필터 활성화

프롬프트에 대한 필터

Text만 선택, 나머지는 임의로 설정해도 됨

모두 재설정

Category	☒ Text	☐ Image Preview	Strength
중요	☒	☐	없음 낮음 중간 높음
모욕	☒	☐	없음 낮음 중간 높음
성적	☒	☐	없음 낮음 중간 높음
폭력	☒	☐	없음 낮음 중간 높음
불법 행위	☒	☐	없음 낮음 중간 높음

☒ 응답에 동일한 유해 카테고리 필터 사용

프롬프트 공격

시스템 명령을 재정의하려는 사용자 입력을 감지하고 차단할 수 있습니다. 시스템 프롬프트가 프롬프트 공격으로 잘못 분류되는 것을 방지하고 필터를 사용자 입력에 선택적으로 적용하려면 입력 태그 지정을 사용하십시오.

☒ 프롬프트 공격 필터 활성화



3. 주제 필터 설정, 아래는 예시이며 설정하지 않아도 무방함

거부된 주제 (10)			편집
Q 주제 찾기			< 1 2 > ⚙
이름	정의		샘플
Travel_planning	여행지 추천, 일정 계획, 경비, 교통편, 숙박 정보 등을 묻거나 안내하는 대화	-	
Sports_discussion	경기 일정, 선수 정보, 분석, 결과 예측, 응원 등 스포츠 전반에 대한 대화	-	
Relationship_advice	연애, 부부, 가족, 친구 등 인간관계 고민이나 해결책, 감정 조절 방법 등을 묻거나 조언하는 대화	-	
Music_recommendation	특정 가수, 장르, 노래 등을 추천하거나 스트리밍, 공연 일정을 묻거나 안내하는 대화	-	
Movie_reviews	영화 추천, 평론, 관람 후기, 개봉 예정작 정보 등을 묻거나 제공하는 대화	-	
learning	학습 자료, 학습 방법, 시험 대비 등 공부 전반에 대한 정보를 묻거나 제공하는 대화	-	
Investment_advice	주식, 채권, 가상자산 등 투자 전략이나 매수·매도 시점, 재무 리스크 등을 묻거나 제공하는 대화	-	
Home_improvement	인테리어, 리모델링, 가구 배치, 수리 방법 등 주거 공간 개선에 관한 팁이나 정보를 묻거나 제공하는 대화	-	
Hobby_activities	취미 생활, 동호회, 취미 용품, 시작 방법 등에 대해 묻거나 안내하는 대화	-	
health	신체적 건강. 우울, 불안, 스트레스 등 심리적 문제나 상담, 대처 방법 등을 묻거나 안내하는 대화	-	

4

단어 필터 추가 - 선택 사항

이러한 필터를 사용하여 사용자 입력 및 모델 응답에서 특정 단어와 문구를 차단할 수 있습니다.

욕설 필터

☒ 욕설 필터링

이 기능을 활성화하면 사용자 입력 및 모델 응답에서 욕설 단어를 차단할 수 있습니다. 단어 목록은 욕설의 전체 정의를 기반으로 하며 변경

사용자 지정 단어 및 문구 추가

가드레일로 차단할 단어 또는 문구를 최대 10,000개(최대 3단어)를 지정합니다. 사용자 입력 또는 모델 응답에 이러한 단어

☒ 단어 및 문구를 수동으로 추가

다음 테이블에 단어와 문구를 수동으로 추가합니다.

☐ 로컬 파일에서 업로드

컴퓨터에 있는 .txt 또는 .csv 파일의 단어와 문구로 다음 테이블을 채웁니다.

☐ S3 객체에서 업로드

S3 객체의 단어와 문구로 다음 테이블을 채웁니다.

예시와 같이 진행

Add words and phrases

Specify up to 10,000 words or phrases (up to 3 words each) to be block-guardrail. A blocked message will show if user input or model response these words or phrases.

- 1 장문
- 2 코노스스
- 3 도요E
- 4 종다
- 5 단술은
- 6 코드
- 7 뱀즈
- 8 DMV
- 9 마우L
- 10 닛선

Cancel

단어 및 문구 보기 및 편집 (0)

Q 단어 및 문구 찾기

Show all

단어 또는 문구

Status

단어 또는 문구가 추가되지 않았습니다.

식별

추가

단어 또는 문구 추가

단어 및 문구를 대량으로 추가

5. 중요

컨텍스트 근거 검사 추가 - 선택 사항 정보

이 정책을 사용하여 모델 응답이 참조 소스에 근거하고 사용자의 쿼리와 관련이 있는지 검증하여 모델 할루시네이션을 필터링할 수 있습니다.

근거

모델 응답이 참조 소스에 제공된 정보에 근거하고 있으며 이를 기반으로 사실적으로 정확한지 검증하고, 정의된 근거 임계값 미만의 응답을 차단합니다.

☒ 근거 검사 활성화

최종 버전은 둘다 비활성화 되어 있음,
비활성화 해도, 데이터와 관련되지 않는 질문을 자연스럽게 막아줌

"오늘 저녁을 추천해줘"라는 질문을 받았을 때, 모델이 저녁 메뉴를 추천해준다면 근거 & 관련성 검사를 활성화 하면 됨

근거 점수 임계값

근거 점수는 모델 응답이 사실적으로 정확하고 소스에 근거했다는 신뢰도를 나타냅니다. 모델 응답의 점수가 정의된 임계값보다 낮으면 응답이 차단되고, 구성되어 있는 차단 메시지가 사용자에게 표시됩니다. [정보](#)

0

0.99

0.15

재설정

(아무것도 차단하지 않음)

(거의 모든 것을 차단함)

관련성

모델 응답이 사용자의 쿼리와 관련이 있는지 확인하고 정의된 관련성 임계값 미만의 응답을 차단합니다.

☒ 관련성 검사 활성화

관련성 점수 임계값

관련성 점수는 모델 응답이 사용자의 쿼리와 관련이 있다는 신뢰도를 나타냅니다. 모델 응답의 점수가 정의된 임계값보다 낮으면 응답이 차단되고, 구성되어 있는 차단 메시지가 사용자에게 표시됩니다. [정보](#)

0

0.99

0.7


재설정

(아무것도 차단하지 않음)

(거의 모든 것을 차단함)

4. Bedrock 리소스 가져오기


상기 제작한 리소스를 아래와 같은 방법으로 가져오고, docker-compose.yaml에 적용



The screenshot shows the AWS Bedrock console. In the left sidebar, under 'Inference and Assessment', 'Cross-region inference' is highlighted. The main panel displays a table of 'Inference profiles (16)'. The table has columns: Name, Model, Description, Inference profile ID, and Inference profile ARN. The profile 'US Anthropic Claude ... Claude 3.5 Haiku' is highlighted in red. Its Inference profile ARN is 'arn:aws:bedrock:us-east-1:19404...'. The text 'AWS MODEL ARN' is written in red above the ARN.

Name	Model	Description	Inference profile ID	Inference profile ARN
US Anthropic Claude ...	Claude 3 Haiku	Routes requests to Anthropic Claude ...	us.anthropic.claude-3-haiku-202...	arn:aws:bedrock:us-east-1:19404...
US Anthropic Claude ...	Claude 3 Opus	Routes requests to Anthropic Claude ...	us.anthropic.claude-3-opus-202...	arn:aws:bedrock:us-east-1:19404...
US Anthropic Claude ...	Claude 3 Sonnet	Routes requests to Anthropic Claude ...	us.anthropic.claude-3-sonnet-20...	arn:aws:bedrock:us-east-1:19404...
US Anthropic Claude ...	Claude 3.5 Haiku	Routes requests to US Anthropic Cla...	us.anthropic.claude-3-5-haiku-2...	arn:aws:bedrock:us-east-1:19404...
US Anthropic Claude ...	Claude 3.5 Sonnet	Routes requests to Anthropic Claude ...	us.anthropic.claude-3-5-sonnet-...	arn:aws:bedrock:us-east-1:19404...
US Anthropic Claude ...	Claude 3.5 Sonnet v2	Routes requests to Anthropic Claude ...	us.anthropic.claude-3-5-sonnet-...	arn:aws:bedrock:us-east-1:19404...


knowledge-base-quick-start-23e9t



The screenshot shows the AWS Knowledge Base console. The 'knowledge-base-quick-start-23e9t' knowledge base is selected. The 'Knowledge base ID' is highlighted in red. The 'State' is 'In Progress' and the 'Creation time' is 'February 14, 2025, 09:09 (UTC+09:00)'.

지식 기반 개요	AWS_KNOWLEDGEBASE_ID
지식 기반 이름 knowledge-base-quick-start-23e9t	지식 기반 ID WGK3R0RLNX
지식 기반 설명 —	상태 진행 중
서비스 역할 AmazonBedrockExecutionRoleForKnowledgeBase_23e9t	생성 날짜 February 14, 2025, 09:09 (UTC+09:00)

chatbot-guardrail



The screenshot shows the AWS Guardrail console. The 'chatbot-guardrail' guardrail is selected. The 'Guardrail ID' is highlighted in red. The 'Versions' section shows a list of versions, with 'Version 7' highlighted in red. The 'Creation time' for Version 7 is 'January 23, 2025, 14:23 (UTC+09:00)'.

가드레일 개요	AWS_GUARDRAIL_ID
이름 chatbot-guardrail	ID oep8zynwyici

규격 초안	AWS_GUARDRAIL_VERSION
이름 규격 초안	생성 날짜
버전 (10)	
Version 7	January 23, 2025, 14:23 (UTC+09:00)
Version 8	January 23, 2025, 14:42 (UTC+09:00)
Version 9	January 23, 2025, 14:44 (UTC+09:00)
Version 10	January 23, 2025, 14:55 (UTC+09:00)
Version 11	January 23, 2025, 15:29 (UTC+09:00)
Version 12	January 24, 2025, 14:27 (UTC+09:00)
Version 13	January 24, 2025, 15:47 (UTC+09:00)
Version 14	February 13, 2025, 12:32 (UTC+09:00)